

Anexo — Trazas de Langfuse

Sep 25, 2026 · @Bruno Cruz

Traza real de una generación completa de novela de 10 capítulos, registrada en Langfuse el 24 de septiembre de 2026 con el proveedor `claude_code` (costes nominales, calculados con los precios de la API).

B.1 · Resumen de la traza

Una generación completa de 10 capítulos duró **45 min 07 s**, consumió **978.662 tokens** y costó **5,96 USD** nominales.

Métrica	Valor
Traza	<code>generacion</code> , 24 de septiembre de 2026, 21:33
Latencia total	45 min 07 s
Tokens	978.662
Coste nominal	5,963077 USD
Coste medio por millón de tokens	≈ 6,09 USD
Scores registrados	17 validadores, uno o varios valores por capítulo e intento

Por su coste y duración, esta traza corresponde a la **primera novela de la demo**, la que el gate rechazó porque el último capítulo abría una promesa que ya nadie podía pagar: lo muestra uno de los valores de `cierre_arco` (0,00). Es un buen ejemplo de observabilidad: la traza explica sola por qué no se publicó.

B.2 · Árbol de spans de la generación

La traza reproduce el bucle del harness: el planner una vez, y por cada capítulo el writer, los dos hooks, el judge y el extractor, con las consultas a la story bible como tool.

latency 45m 07s

cost \$5.963077 ⓘ

tokens 978,662 ⓘ

session ↗

■ adecuacion_to... 0.95 ⓘ , 0.93 ⓘ , 0.95 ⓘ , 0.95 ⓘ , 0.95 ⓘ , 0.92 ⓘ , 0.95 ⓘ , 0.88 ⓘ , 0.92 ⓘ , 0.95 ⓘ , 0.95 ⓘ

■ calidad_prosa 1.00 ⓘ , 1.00 ⓘ , 1.00 ⓘ , 0.86 ⓘ , 0.86 ⓘ , 1.00 ⓘ , 1.00 ⓘ , 1.00 ⓘ , 1.00 ⓘ , 1.00 ⓘ , 1.00 ⓘ ,

+17

🔍 Search

↔ generacion

45m 07s

🔑 consultar_story_bible
0.00s

🌀 planner
1m 07s \$0.183506

🔑 consultar_story_bible
0.01s

↔ capitulo
2m 16s

🔑 consultar_story_bible
0.00s

🌀 writer
1m 25s \$0.203647

↔ hook_policy
0.02s

↔ hook_capitulo
0.08s

🔑 consultar_story_bible
0.02s

🌀 judge
50.66s \$0.084574

🌀 extractor
17.65s \$0.05228

↔ generacion

2026-09-24 21:33:14.834

latency 45m 07s

cost \$5.963077 ⓘ

tokens 978,662 ⓘ

Preview ▾

Input

null

Output

undefined

✎ Correct output

```
graph TD; generacion["generacion  
45 min 07 s · 5,96 USD"] --> consultar_story_bible_tool["consultar_story_bible  
tool"]; generacion --> planner["planner  
1 min 07 s · 0,18 USD"]; generacion --> capitulo["capitulo × 10  
ej.: 2 min 16 s"]; generacion --> extractor["extractor  
17,65 s · 0,05 USD"]; planner --> consultar_story_bible["consultar_story_bible"]; planner --> writer["writer  
1 min 25 s · 0,20 USD"]; planner --> hook_policy["hook_policy  
0,02 s"]; planner --> hook_capitulo["hook_capitulo  
0,08 s"]; planner --> judge["judge  
50,66 s · 0,08 USD"]; extractor --> hook_policy; extractor --> hook_capitulo; extractor --> judge;
```

Page 2 of 8

El orden real es `hook_policy` antes que `hook_capitulo`: primero el guardrail de palabras prohibidas y después los validadores del capítulo. Los hooks son programáticos y apenas cuestan tiempo; casi toda la latencia está en las llamadas al modelo.

B.3 · Coste y latencia por rol

Un capítulo que pasa a la primera cuesta unos **0,34 USD** y 2,5 minutos; los reintentos y las correcciones explican alrededor del **40 %** del coste total de la novela.

Span	Modelo	Latencia	Coste	Tokens
planner (una vez por novela)	Opus 5.5	1 min 07 s	0,18 USD	—
writer (por capítulo)	Opus 5.5	1 min 25 s	0,20 USD	17.898
judge (por capítulo)	Sonnet 5	50,66 s	0,085 USD	—
extractor (por capítulo)	Sonnet 5	17,65 s	0,052 USD	—
hook_policy y hook_capitulo	Sin modelo	0,02 s y 0,08 s	0	—
consultar_story_bible (tool)	Sin modelo	0,00–0,02 s	0	—

Lectura del coste:

- Diez capítulos a la primera costarían unos 3,40 USD, más 0,18 USD del planner: unos **3,60 USD**.
- La traza costó **5,96 USD**. La diferencia, unos 2,40 USD, son correcciones del editor, reescrituras y nuevas evaluaciones del judge.
- **Consecuencia comercial:** mejorar la calidad a la primera (con el tuning de prompts) también baja el coste. Es la palanca de coste más directa, antes incluso que el prompt caching.

Los valores por capítulo son de un capítulo de muestra (el capítulo 1); los demás varían con su longitud y con los reintentos.

B.4 · Scores por validador

Los validadores semánticos quedan entre 0,70 y 1,00; los fallos visibles son programáticos (`longitud` y `cierre_arco`) y provocaron las reescrituras y el rechazo final.

Scores

adecuacion_tono	0.95, 0.93, 0.95, 0.95, 0.95, 0.92, 0.95, 0.88, 0.92, 0.95, 0.95, 0.95, 0.95
calidad_prosa	1.00, 1.00, 1.00, 0.86, 0.86, 1.00, 1.00, 1.00, 1.00, 1.00, 1.00, 1.00, 0.86
cierre_arco	0.00, 1.00, 0.97, 0.95, 0.90, 0.92, 0.95, 0.92, 0.90, 0.96, 0.95, 0.95, 0.90, 1.
coherencia_personajes	0.97, 0.98, 0.93, 0.95, 0.94, 0.93, 0.90, 0.95, 0.97, 0.95, 0.95, 0.95, 1.00
consistencia_factica	0.98, 1.00, 0.97, 1.00, 0.93, 1.00, 0.97, 1.00, 0.97, 1.00, 0.97, 1.00, 0.95, 1.
cumplimiento_brief	0.75, 0.75, 0.80, 1.00, 1.00, 1.00, 1.00, 0.75, 1.00, 0.80, 0.80, 0.88, 0.70
elementos_obligatorios	1.00
estructura_edicion	1.00
integridad_pov	0.98, 0.96, 0.98, 1.00, 1.00, 0.98, 1.00, 1.00, 1.00, 1.00, 1.00, 0.98, 1.00
invencion_destinatario	0.00, 0.00, 0.00, 0.00, 0.00, 0.00, 0.00, 0.00, 0.00, 0.00, 0.00, 0.00, 0.00
longitud	1.00, 0.00, 1.00, 1.00, 0.00, 1.00, 1.00, 1.00, 1.00, 1.00, 0.00, 1.00, 1.00
nombres_exactos	1.00, 1.00, 1.00, 1.00, 1.00, 1.00, 1.00, 1.00, 1.00, 1.00, 1.00, 1.00, 1.00

Validador	Tipo	Valores	Rango	Lectura
nombres_exactos	Programático	13	1,00	Todos los capítulos usan los nombres de la story bible
invencion_destinatario	Semántico (recuento)	13	0,00	Ningún hecho inventado sobre el destinatario (0 = bien)
integridad_pov	Semántico	12	0,96–1,00	Persona y focalización estables
consistencia_factica	Semántico	14	0,93–1,00	Sin contradicciones con la story bible
calidad_prosa	Semántico	12	0,86–1,00	Tres evaluaciones por debajo de 1
adecuacion_tono	Semántico	13	0,88–0,95	Tono adecuado a la ocasión y la edad
coherencia_personajes	Semántico	13	0,90–1,00	Personajes coherentes entre capítulos
cumplimiento_brief	Semántico	13	0,70–1,00	El criterio más bajo: candidato para el tuning

Validador	Tipo	Valores	Rango	Lectura
longitud	Programático	13	0 o 1	Tres suspensos que provocaron reescrituras
cierre_arco	Programático	14	0,00–1,00	Un 0,00: la promesa sin pagar que rechazó la versión
elementos_obligatorios	Programático (novela)	1	1,00	Todos los elementos personalizados aparecen
estructura_edicion	Programático (novela)	1	1,00	Diez capítulos, títulos e índice correctos

Cómo leerlos:

- **Más de 10 valores por validador** significa que hubo evaluaciones repetidas: cada corrección del editor o reescritura vuelve a pasar por los validadores.
- **Dos escalas distintas.** Casi todos van de 0 a 1 con 1 = cumple; `invencion_destinatario` y `temas_excluidos` son recuentos de problemas, con 0 = cumple. Unificarlas está en la lista post-demo.
- **Validadores de novela.** `elementos_obligatorios` y `estructura_edicion` se calculan una vez sobre la novela completa.
- La traza tiene 17 validadores con score; la captura muestra los 12 primeros.


B.5 · Vista agregada del proyecto y prompts versionados

El panel del proyecto registra 5 trazas en el periodo mostrado (3 generaciones y 2 exportaciones a PDF) por un coste total de 7,33 USD nominales.



El gráfico de costes del panel aparece vacío («No data»), aunque el total sí se calcula: el coste se registra en cada llamada, pero el panel no lo desglosa por modelo. Conviene revisarlo si se quiere enseñar esa vista.

Prompt versionado del writer. Cada llamada al modelo muestra el prompt de sistema con el que se ejecutó, que viene de la gestión de prompts de Langfuse, sincronizada desde el repositorio con el hash de git.



Prompt	Versiones en Langfuse	Motivo del cambio
writer	1 → 2	Restricciones de promesas en la regeneración dirigida (TO-047)

Prompt	Versiones en Langfuse	Motivo del cambio
extractor	1 → 2	Reapertura de promesas por alias (TO-047)
planner, editor, judge, interviewer	1	Sin cambios

B.6 · Hallazgos de observabilidad y mejoras

La instrumentación cumple lo que exige el alcance (sesión, spans por rol y tool, scores y coste por llamada); quedan cuatro mejoras que harían las trazas más legibles.

Hallazgo	Efecto	Mejora propuesta
La traza raíz <code>generacion</code> tiene Input <code>null</code> y Output <code>undefined</code>	No se ve de un vistazo qué novela es ni cómo terminó	Registrar como entrada el <code>novel_id</code> y la versión, y como salida el estado final (publicada o rechazada) con su motivo, sin datos personales del brief
El gráfico de costes del panel sale vacío	El panel no enseña el desglose por modelo	Revisar cómo se envía el modelo y el coste de cada llamada a Langfuse
Dos escalas de score (0-1 con 1 = cumple y recuentos con 0 = cumple)	Dificulta leer los scores juntos y construir la tabla de evaluación	Unificar la dirección de todos los scores (post-demo)
La API de scores de Langfuse devuelve 410 en la organización	Los scores solo se pueden revisar en la interfaz	Comprobarlos en la interfaz; documentado en el README

Qué demuestra la traza para la propuesta:

- **El coste por novela es medible:** 5,96 USD en esta traza, y 6,04 USD en la novela publicada de la demo.
- **Cada rechazo tiene explicación:** el 0,00 de `cierre_arco` señala por qué el gate no publicó.
- **El coste de los reintentos se ve:** alrededor del 40 % del total, lo que convierte el tuning de calidad en una palanca de coste.

- **Las unidades de Langfuse por novela** se pueden medir en esta traza, para confirmar el supuesto de 500 unidades del análisis económico.